
Comparativa de cinco modelos de Aprendizaje Automático Supervisado aplicados a la clasificación de la calidad del aire

Yare Brea Espinosa
Universidade da Coruña
A Coruña, España
yare.bespinosa@udc.es

Raúl Cayón Fernández
Universidade da Coruña
A Coruña, España
r.cayonf@udc.es

Pablo Fernández Ríos
Universidade da Coruña
A Coruña, España
pablo.fernandez.rios@udc.es

Paula Rodil Lamas
Universidade da Coruña
A Coruña, España
paula.rodil@udc.es

Abstract

Los modelos de aprendizaje automático clásicos son ampliamente utilizados hoy en día en toda clase de problemas. En este trabajo se evalúan cinco de estos modelos (Redes de Neuronas Artificiales, Máquinas de Vectores de Soporte, k -Vecinos más Cercanos, Árboles de Decisión y Regresión Simbólica mediante DoME) sobre un conjunto de datos multiclase de calidad del aire. Los resultados revelan un rendimiento altamente competitivo, con todos los algoritmos superando un F1-Score global de 0.92. Las Máquinas de Vectores de Soporte (SVM) y las Redes de Neurona Artificiales (ANN) demostraron una ligera superioridad al modelar fronteras no lineales complejas. Finalmente, el estudio identifica el desbalanceo en la predicción de episodios críticos como la principal limitación técnica, proponiendo estrategias de remuestreo para futuros despliegues físicos.

1 Introducción

Comenzamos el presente informe con una breve introducción del problema a resolver, su relevancia en el escenario internacional y los objetivos por alcanzar.

1.1 Contexto general

En un siglo XXI donde el cambio climático es una realidad cuyos efectos negativos son cada vez más acentuados, la calidad del aire está en el punto de mira dado su estrecho vínculo con la salud de los humanos y el resto de seres vivos. Es, por tanto, una de las cuestiones más estudiadas y de las que más información objetiva se dispone.

Tanto es así, que la Agencia de Protección Medioambiental de EEUU (US EPA) creó en 1999 el Air Quality Index (AQI), un índice para clasificar, en función de una fórmula matemática (véase ecuación 1), la calidad del aire en una de las 6 categorías posibles (desde "Bueno" hasta "Peligroso"). Para dar contexto, la tabla 1 a continuación contiene las distintas clases establecidas por la organización:

Los pasos concretos pueden consultarse en la sección IV de la página oficial (U.S. Environmental Protection Agency (EPA) (2024)) pero, en líneas generales, el procedimiento sería el que sigue:

1. Medir la concentración de cada contaminante (PM2.5, CO, SO2...) por separado.

Table 1: Categorías y rangos del Índice de Calidad del Aire (AQI)

Categoría de Calidad del Aire	Valores AQI
Buena (Good)	0 - 50
Moderada (Moderate)	51 - 100
Dañina para grupos sensibles	101 - 150
Dañina (Unhealthy)	151 - 200
Muy Dañina (Very Unhealthy)	201 - 300
Peligrosa (Hazardous)	301+

2. Asignar un "rango" en escala AQI a partir de la misma.
3. Aplicar la fórmula para obtener un índice correspondiente al contaminante analizado y redondearlo al entero más cercano.
4. La calidad del aire será la clase a la que pertenezca el índice más alto de todos.

$$I_p = \frac{I_{Hi} - I_{Lo}}{BP_{Hi} - BP_{Lo}}(C_p - BP_{Lo}) + I_{Lo} \quad (1)$$

Donde:

- I_p : es el subíndice de calidad del aire calculado para el contaminante específico p .
- C_p : es la concentración real medida de dicho contaminante p .
- BP_{Hi} y BP_{Lo} : son los puntos de corte de concentración (alto y bajo, respectivamente) entre los que se encuentra C_p , tabulados por la agencia.
- I_{Hi} y I_{Lo} : son los valores del índice AQI que corresponden exactamente a los puntos de corte BP_{Hi} y BP_{Lo} .

Así pues, una evaluación acerca de dicha problemática haciendo uso de Modelos de Aprendizaje Supervisado (tales como k-NN, SVM) es de especial interés, no solo desde el punto de vista técnico para comparar los rendimientos de dichos modelos en un escenario así, sino para encontrar relaciones y patrones ocultos en parámetros no contemplados explícitamente por el AQI (e. g. densidad de población), que podrían pasar desapercibidos con herramientas de análisis de datos tradicionales.

1.2 Motivación y objetivos

La necesidad de resolver este problema usando algoritmos de AA radica en las ventajas que proporcionan estos modelos frente a estaciones físicas tradicionales de monitorización del aire. Dichas ventajas se pueden reducir a tres ejes principales:

1. **Optimización económica y tolerancia a fallos:** Las estaciones cuentan con sensores de alto nivel para poder medir con precisión valores de PM2.5, SO2, PM10, etc. A mayores del gasto de su adquisición e instalación, hay que sumar el mantenimiento y reemplazo de piezas que técnicos especializados llevan a cabo frecuentemente, por lo que la inversión de capital termina siendo elevada. Gracias a la capacidad del *Machine Learning* de encontrar relaciones ocultas y realizar predicciones en consecuencia (aún con datos inexactos), es posible prescindir de algunas mediciones y seguir obteniendo buenos resultados.
2. **Cobertura territorial:** A raíz de las limitaciones económicas comentadas, es habitual que queden zonas habitadas sin monitorizar. Un modelo que tenga en cuenta parámetros sencillos de registrar, como la temperatura o la humedad; o características geográficas y demográficas, como la proximidad a zonas industriales, es capaz de generalizar y suplir esta carencia, proporcionando una estimación fiable.
3. **Capacidad predictiva temporal:** La fórmula determinista del AQI únicamente puede evaluar la calidad del aire una vez se conocen las muestras químicas. Por el contrario, uno de los puntos fuertes de un modelo de Aprendizaje Automático es que puede adelantarse a los hechos. Tan solo alimentándolo con un pronóstico meteorológico (por ejemplo, temperatura y humedad esperadas) junto con el contexto demográfico, es posible predecir un escenario de aire "Pobre" o "Peligroso" con antelación, permitiendo actuar en consecuencia.

En base a esta motivación, el objetivo principal de este trabajo es entrenar y evaluar distintos sistemas de clasificación supervisada capaces de categorizar la calidad del aire de forma eficiente. Concretamente, se implementarán y compararán cinco aproximaciones: Redes Neuronales Artificiales (ANN), Máquinas de Vectores de Soporte (SVM), k-Nearest Neighbors (k-NN), Árboles de Decisión y DoME, Rivero et al. (2022), un algoritmo determinista de Regresión Simbólica capaz de modelar expresiones matemáticas explícitas. Por otra parte, se analizará el impacto de sus respectivos hiperparámetros mediante un proceso de validación cruzada y se evaluará su rendimiento empleando métricas robustas, con el fin de determinar qué algoritmo resuelve mejor este problema del mundo real.

2 Descripción del problema

La resolución del problema se plantea como una tarea de clasificación supervisada multiclase: dado un vector de 9 atributos numéricos que describen condiciones medioambientales y demográficas de una región, el modelo debe ser capaz de encontrar relaciones entre los datos para clasificar cada instancia en una de las 4 categorías de la variable objetivo (*Bueno, Moderado, Pobre y Peligroso*). Formalmente, se busca aprender una función $f : \mathbb{R}^9 \rightarrow \{\text{Bueno, Moderado, Pobre, Peligroso}\}$ a partir de un conjunto de entrenamiento etiquetado.

Como ya se mencionó en la introducción, el enfoque clásico para la evaluación de la calidad del aire es el AQI, un índice descriptivo que traduce concentraciones de contaminantes individuales a una escala numérica basándose en umbrales fijos. Las limitaciones de este enfoque son claras: el AQI trabaja únicamente con mediciones de contaminantes en un ámbito local y no es capaz de capturar interacciones entre variables ni incorporar factores contextuales.

En contra, un modelo de aprendizaje automático ofrece muchas ventajas. En primer lugar, incorpora variables contextuales (temperatura, humedad, proximidad industrial, densidad de población), lo que le permite capturar relaciones complejas que el AQI ignora. En segundo lugar, una vez entrenado, el modelo puede generalizar a nuevas instancias sin depender de umbrales predefinidos, ya que los aprende directamente de los datos. No obstante, conviene señalar que ambos enfoques no son excluyentes sino complementarios. De hecho, es habitual el entrenamiento de modelos de aprendizaje automático para predecir directamente el valor del AQI.

2.1 Restricciones y alcance del problema

El dataset seleccionado y el planteamiento del problema presentan varias limitaciones que condicionan el alcance de los resultados:

- **Sesgo geográfico:** Según la documentación del dataset en Kaggle, los datos seleccionados provienen de estaciones meteorológicas del sur y sureste asiático, regiones que suelen estar más expuestas a los riesgos de la contaminación. Esto limita el rango de valores que pueden tomar los datos. Por ejemplo, temperaturas inferiores a 15°C son prácticamente inexistentes, por lo que si tratásemos de predecir nuevas instancias procedentes de estaciones meteorológicas del norte de Europa, el modelo sería incapaz de clasificarlas de forma fiable.
- **Carácter sintético de los datos:** Como se detalla en la sección de propiedades de datos, el dataset contiene valores físicamente imposibles, lo que sugiere que los datos fueron modificados artificialmente. Estos valores podrían alterar el comportamiento de los modelos, por lo que los resultados no deben interpretarse como los de un entorno real.
- **Ausencia de dimensión temporal y espacial:** El dataset no incluye marcas temporales ni coordenadas geográficas, por lo que el sistema no puede ser capaz de modelar series temporales ni incorporar información de geolocalización.
- **Número reducido de categorías:** El dataset utiliza 4 categorías para la clasificación de la calidad del aire, frente a las 6 establecidas por el AQI. Aunque son suficientes para resolver el problema de clasificación, un mayor nivel de detalle proporcionaría resultados más interpretables y realistas.

2.2 Supuestos asumidos

El planteamiento del problema asume las siguientes condiciones:

- Las instancias del conjunto de datos son independientes entre si, ya que no existe relación espacial ni temporal entre ellas.
- La relación entre los atributos y la calidad del aire puede ser capturada por los modelos de clasificación seleccionados (ANN, SVM, k-NN, Árboles de Decisión y DoME).
- Las 4 categorías de la variable objetivo son excluyentes y completas: toda instancia pertenece a una clase, y no existen instancias fuera de estas categorías.

2.3 Descripción de la base de datos

Este proyecto utiliza el dataset *Air Quality and Pollution Assessments*, creado por Mujtaba Mateen y disponible en la plataforma Kaggle. El dataset está licenciado bajo la Apache License 2.0.

La base de datos seleccionada se centra en la evaluación de la calidad del aire a través de diferentes regiones, recogiendo 5000 instancias de datos que combinan factores medioambientales (temperatura, humedad, concentraciones de contaminantes) y demográficos (densidad de población, proximidad a zonas industriales) que influyen los niveles de contaminación.

2.3.1 Origen de los datos

Según la documentación aportada por el autor, el dataset fue creado a partir de datos provenientes de múltiples fuentes del mundo real que monitorizan la calidad del aire y factores medioambientales:

- World Health Organization (WHO)
- World Bank Data

2.3.2 Metodología de recolección

También se menciona que los datos fueron recolectados mediante técnicas de *web scraping* y posteriormente fusionados con otros conjuntos de datos ya preparados. Sin embargo, como se explica en la sección de propiedades de los datos, la presencia de valores físicamente imposibles sugiere que el proceso de fusión o generación introdujo valores artificiales. Esto indica que el dataset tiene, al menos parcialmente, un carácter sintético, lo que debe considerarse a la hora de interpretar los resultados obtenidos.

2.4 Propiedades de los datos

Con el objetivo de comprender el dataset que vamos utilizar, incluimos a continuación una serie de propiedades de interés. Algunas de las gráficas fueron extraídas directamente de la sección de discusión de Kaggle.

2.4.1 Dimensionalidad y estructura

El conjunto de datos está formado por 5000 instancias. Cada instancia está descrita por nueve atributos predictivos y una variable objetivo categórica:

Características principales:

1. Temperatura (°C): Temperatura media de la región.
2. Humedad (%): Humedad relativa registrada en la región.
3. Concentración de PM2.5 ($\mu\text{g}/\text{m}^3$): Niveles de partículas finas.
4. Concentración de PM10 ($\mu\text{g}/\text{m}^3$): Niveles de partículas gruesas.
5. Concentración de NO₂ (ppb): Niveles de dióxido de nitrógeno.
6. Concentración de SO₂ (ppb): Niveles de dióxido de azufre.
7. Concentración de CO (ppm): Niveles de monóxido de carbono.
8. Proximidad a zonas industriales (km): Distancia a la zona industrial más cercana.
9. Densidad de población (personas/km²): Número de personas por kilómetro cuadrado en la región.

10. Niveles de calidad del aire (variable objetivo):

- Bueno: Aire limpio con bajos niveles de contaminación.
- Moderado: Calidad del aire aceptable, pero con algunos contaminantes presentes.
- Pobre: Contaminación notable que puede causar problemas de salud en grupos sensibles.
- Peligroso: Aire altamente contaminado que supone graves riesgos para la salud de la población.

Una ventaja del problema a resolver es que todos los atributos predictivos son numéricos continuos, lo que permite prescindir de técnicas de codificación en la matriz de características. En cuanto a la variable objetivo categórica, algoritmos como los Árboles de Decisión, k-NN o SVM la procesan internamente. Sin embargo, para el entrenamiento de la Red de Neuronas Artificiales (ANN) sí ha sido imprescindible implementar una codificación *One-Hot Encoding*, transformando las 4 clases de calidad del aire en un vector binario de 4 dimensiones, correspondiente a las neuronas de la capa de salida del modelo.

Además, el dataset no contiene valores faltantes ni duplicados en ninguna de sus variables, lo que simplifica la fase de preprocesamiento al no requerir técnicas de rellenado de datos.

2.4.2 Estadísticas descriptivas

La Tabla 2 resume las principales estadísticas descriptivas de cada atributo numérico del dataset.

Table 2: Estadísticas descriptivas de los atributos del dataset.

Variable	Mín.	Q1	Mediana	Q3	Máx.	Media	Desv. típ.
Temperatura (°C)	13,40	25,10	29,00	34,00	58,60	30,03	6,72
Humedad (%)	36,00	58,30	69,80	80,30	128,10	70,06	15,86
PM2.5 ($\mu\text{g}/\text{m}^3$)	0,00	4,60	12,00	26,10	295,00	20,14	24,55
PM10 ($\mu\text{g}/\text{m}^3$)	-0,20	12,30	21,70	38,10	315,80	30,22	27,35
NO ₂ (ppb)	7,40	20,10	25,30	31,90	64,90	26,41	8,90
SO ₂ (ppb)	-6,20	5,10	8,00	13,73	44,90	10,01	6,75
CO (ppm)	0,65	1,03	1,41	1,84	3,72	1,50	0,55
Proximidad ind. (km)	2,50	5,40	7,90	11,10	25,80	8,43	3,61
Densidad pobl. (pers./km ²)	188	381	494	600	957	497,42	152,75

2.4.3 Distribución de la variable objetivo




Figure 1: Distribución de las categorías de calidad del aire en el conjunto de datos.

Al generar gráficos que muestran la distribución de valores en la calidad del aire, observamos que nuestra variable objetivo está desbalanceada. La distribución es la siguiente: *Bueno* con 2000 instancias (40,0%), *Moderado* con 1500 instancias (30,0%), *Pobre* con 1000 instancias (20,0%) y *Peligroso* con 500 instancias (10,0%). La clase mayoritaria (*Bueno*) cuadruplica en tamaño a la clase minoritaria (*Peligroso*).

Esto implica que los modelos resultantes podrían obtener porcentajes de clasificación muy altos en métricas como la *accuracy*, que resultan engañosas al no distinguir entre clases. Las métricas de evaluación adecuadas para este contexto se explican en una sección posterior.

Por otra parte, una técnica que permitiría corregir este desbalanceo es el *resampling*, que consiste en modificar la distribución del dataset de entrenamiento para equilibrar las clases. No obstante, al no ser empleado durante el desarrollo no extenderemos su explicación.

2.4.4 Distribución de los atributos

Para analizar la distribución de cada variable se generan histogramas, mostrados en la Figura 2.




Figure 2: Histogramas de distribución de los atributos del conjunto de datos.

- Los valores de la temperatura están sesgados a la derecha, con valores que se concentran entre 20°C y 35°C. Siendo valores atípicos aquellos menores a 15°C y mayores a 45°C.
- Los valores de la humedad están ligeramente sesgados a la derecha, con una gran cantidad de valores concentrados entre 50% y 80%. Siendo prácticamente inexistentes los valores menores a un 40%. Se debe señalar que existen valores superiores a un 100%, físicamente incoherentes.
- Los niveles de PM2.5 se concentran en la parte izquierda de la distribución, con valores menores a 50 $\mu\text{g}/\text{m}^3$, lo que sugiere niveles de contaminación bajos en la mayoría de instancias. El atributo PM10 muestra un comportamiento similar, con valores concentrados por debajo de 60 $\mu\text{g}/\text{m}^3$. En ambas distribuciones, valores superiores a 100 $\mu\text{g}/\text{m}^3$ se corresponden con periodos de muy elevada contaminación.
- En cuanto a la variable NO₂, la moda se sitúa entre 20ppb y 30ppb. Al igual que en casos anteriores, la distribución está sesgada a la derecha, lo que indica que la mayoría de mediciones corresponden a periodos de baja contaminación.
- Los niveles de SO₂ se concentran entre valores de 5ppb y 10ppb. Siendo valores atípicos los inferiores a 0ppb y superiores a 30ppb.

- La distribución de CO presenta una moda claramente definida en torno a 1,0 ppm con una menor concentración en 1,5 ppm, lo que indica picos ocasionales en los niveles de CO.
- Observamos también que la proximidad a áreas industriales es bimodal, con un pico alrededor de 5km de distancia y otro alrededor de 12km de distancia. Esto indica que la mayoría de datos se recogen en áreas cercanas o moderadamente alejadas de zonas industriales.
- Por último, la densidad de población es la distribución más parecida a una distribución normal. Con muchos valores repartidos a lo largo de todo el rango, aunque concentrados entre 300 personas/km² y 650 personas/km².

2.4.5 Valores anómalos

El análisis de los rangos de cada variable muestra la presencia de valores que, desde un punto de vista físico, resultan cuestionables:

- **Humedad superior al 100%:** Existen instancias con valores de humedad relativa superiores al 100%, alcanzando un máximo de 128,1%. La humedad relativa tiene un límite físico del 100% (o ligeramente superior en condiciones excepcionales de sobresaturación).
- **Temperaturas superiores a 50°C:** Se registran también instancias con temperaturas por encima de los 50°C, con un máximo de 58,6°C. Estas temperaturas ambientales no son representativas de condiciones habitables en ninguna región del planeta.
- **Valores negativos en SO₂ y PM10:** Existen también concentraciones negativas de SO₂ (mínimo de -6,2 ppb) y con PM10 negativo (-0,2 µg/m³). Las concentraciones de contaminantes no pueden ser negativas en la realidad.

Todas estas evidencias sugieren que el dataset fue generado de forma sintética o que contiene errores en la generación de los datos. Estas anomalías limitan la validez de los resultados del dataset en un contexto real.

2.4.6 Relación entre atributos y variable objetivo

Los diagramas de caja y dispersión de la Figura 3 permiten observar cómo influyen los valores de cada atributo en la calidad del aire.




Figure 3: Análisis visual de las variables del dataset según el nivel de calidad del aire.

- La temperatura muestra una relación directamente proporcional con el empeoramiento de la calidad del aire: valores bajos (15°C - 30°C) se asocian con buena calidad, mientras que valores elevados se corresponden con niveles dañinos.

- La humedad sigue una distribución similar: cuanto mayor es el porcentaje de humedad, peor es la calidad del aire.
 - Los niveles de PM2.5 y PM10 tienden a presentar cuartiles con valores bajos. No obstante, cuando la calidad del aire es pobre o dañina, el rango intercuartílico es muy amplio, con una gran cantidad de valores atípicos que se corresponden con concentraciones de partículas peligrosas.
 - Los gráficos tanto de NO₂ como de SO₂ son muy similares. El rango es amplio para niveles dañinos y malos. Cuando la calidad del aire es buena, el rango es menor y la mediana se sitúa alrededor de los 20 ppb para NO₂ y 10 ppb para SO₂. En calidad moderada tanto la mediana como el rango se incrementan.
 - La distribución de CO presenta un rango muy estrecho para buena calidad del aire, al contrario que para la dañina. Cuando menor es la concentración de CO (valores menores a 1,4ppm) mejor es la calidad del aire, cuando repuntan (mayores a 1.5) la calidad del aire empeora progresivamente, hasta ser dañina con valores de hasta 3.5 ppm.
- La proximidad a áreas industriales muestra una relación inversamente proporcional con la calidad del aire: a mayor distancia de una zona industrial, mejor calidad. Para distancias intermedias (5–10 km), los valores se solapan entre calidad buena y moderada. Se observa una gran cantidad de valores atípicos en todas las categorías.
- Cabe destacar la variable densidad de población donde no existe presencia de datos atípicos en sus diagramas de caja.




Figure 4: Relación entre la proximidad a zonas industriales y la densidad de población, clasificada por calidad del aire.

Una propiedad destacable de los datos es la relación entre la proximidad a zonas industriales y la calidad del aire. Como se observa en la Figura 4, esta variable es inversamente proporcional a la calidad del aire. En otras palabras, cuanto mayor es la distancia a una zona industrial, mejor es la calidad del aire registrada.

2.5 Métricas a emplear

A la hora de seleccionar las métricas de evaluación es fundamental tener en cuenta que la variable objetivo está significativamente desbalanceada. Una métrica como la *accuracy*, que simplemente calcula el total de predicciones correctas sobre el total de predicciones, no es suficiente para este problema:

$$Accuracy = \frac{\text{Número de predicciones correctas}}{\text{Número total de predicciones}} = \frac{\sum_i C_{ii}}{\sum_i \sum_j C_{ij}} \quad (2)$$

donde C representa la matriz de confusión. El problema de esta métrica es que, en un escenario desbalanceado, la clase mayoritaria domina el cálculo. En nuestro caso, un modelo podría obtener

valores de *accuracy* óptimos, simplemente por clasificar correctamente las instancias no dañinas de calidad del aire, que suponen el 90% de las instancias de la clase, pero cometer graves errores en la clasificación del aire dañino, lo que tendría graves consecuencias.

Esta casuística es especialmente relevante desde el punto de vista del problema real: clasificar erróneamente aire peligroso como bueno (falso negativo) podría tener consecuencias directas sobre la salud pública, ya que se omitiría una alerta necesaria. Por el contrario, el error inverso, clasificar aire bueno como peligroso (falso positivo), simplemente generaría una alerta innecesaria, con un coste considerablemente más bajo.

Para paliar los efectos del desbalanceo entre clases, se deben utilizar también métricas calculadas de forma individual para cada clase. Esto implica adoptar un enfoque *uno contra todos*, en el que cada clase se evalúa de forma independiente frente al resto. Por ejemplo, para la clase *dañino*:

- **Verdadero positivo:** La instancia era dañina y se predijo dañina.
- **Falso positivo:** La instancia no era dañina (buena, moderada o pobre) y se predijo como dañina.
- **Verdadero negativo:** La instancia no era dañina y se predijo como otra clase.
- **Falso negativo:** La instancia era dañina y se predijo como otra clase.

Precision (VPP). Mide la proporción de predicciones positivas que realmente son correctas. Una *precision* alta indica que, cuando el modelo predice una clase determinada, lo hace con fiabilidad:

$$Precision = \frac{VP}{VP + FP} \quad (3)$$

Recall (sensibilidad). Mide la proporción de instancias reales de una clase que el modelo identifica correctamente. Un *recall* alto indica que el modelo detecta la mayoría de casos de esa clase.:

$$Recall = \frac{VP}{VP + FN} \quad (4)$$

Como se ha justificado anteriormente, esta métrica, sobre la especificidad (tasa de instancias no pertenecientes a esa clase correctamente identificadas), será nuestro indicador prioritario a la hora de auditar el rendimiento del modelo sobre las clases de mayor peligro.

F1-score. Es la media armónica de *precision* y *recall*, proporcionando un equilibrio entre ambas métricas. Resulta especialmente útil cuando existe desbalanceo, ya que penaliza valores bajos en cualquiera de las dos:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (5)$$

Estas tres métricas se calculan de forma independiente para cada una de las cuatro clases. Para obtener una medida resumen del rendimiento global del modelo, existen dos estrategias habituales de promediado del F1-score:

- **F1 macro:** Calcula el F1 para cada clase y promedia los resultados sin tener en cuenta el tamaño de cada clase. Al otorgar el mismo peso a todas las clases, penaliza los fallos en clases minoritarias, lo que resulta adecuado cuando se busca un rendimiento equilibrado en todas las categorías.
- **F1 ponderado (weighted):** Igual que el macro, pero pondera cada resultado por el número de instancias en su clase correspondiente. Refleja mejor el rendimiento global del modelo, aunque puede ocultar un rendimiento deficiente en las clases con menor representación.

En este trabajo se ha optado por emplear el **F1 ponderado** como métrica agregada de referencia. Esta decisión se justifica por dos motivos. En primer lugar, dado que las métricas se calculan de forma independiente para cada clase, ya se dispone de información detallada sobre el rendimiento en las

clases minoritarias a través del *recall* y el F1-score por clase, por lo que la métrica agregada se utiliza como un indicador global del comportamiento del modelo. En segundo lugar, el F1 ponderado refleja con mayor fidelidad el rendimiento real sobre el conjunto de datos, al tener en cuenta la distribución de las clases tal y como aparece en el problema.

Por último, la matriz de confusión complementa las métricas numéricas al proporcionar una representación visual de los aciertos y errores del modelo. A diferencia de las métricas anteriores, que concentran el rendimiento en un único valor, la matriz de confusión permite identificar patrones de error específicos. Por ejemplo, si el modelo confunde sistemáticamente la clase *moderado* con *pobre*, un error que tendría sentido al tratarse de categorías adyacentes en la escala de calidad del aire. Esta información resulta valiosa para orientar posibles mejoras en el modelo.

3 Estado del Arte

En la última década, impulsado por el creciente auge y refinamiento de técnicas de Aprendizaje Máquina, ha aumentado notablemente el interés de la comunidad en la aplicación de dichas técnicas frente a las tradicionales para solucionar la problemática tratada en este informe, como ya notaron en 2018 Rybarczyk and Zalakeviciute (2018), recalcando en especial la utilidad de Ensemble, ANN y SVM en este ámbito (véase figura 5) En consecuencia, no fue un gran reto recabar información útil sobre el tema a partir de plataformas como Google Scholar o IEEE Xplore.




Figure 5: Proporción de algoritmos de AA usados en el ámbito de la calidad del aire según el estudio de Rybarczyk y Zalakeviciute.

Antes de empezar, conviene tener en cuenta dos características de la literatura que aborda esta problemática:

- La gran mayoría de estudios (incluido el dataset con el que trabajaremos) trabajaron con datos recopilados en regiones asiáticas, especialmente del subcontinente indio (Pakistán, Bangladesh, India...).
- Aparte de la clasificación en niveles AQI, es muy habitual el uso de algoritmos clásicos de regresión para predecir los valores concretos de dicho índice, o las proporciones de las partículas y químicos contaminantes.

Esto no es un gran problema, ya que muchas de las observaciones y conclusiones extraídas de experimentos con regresión son de interés para aprender más del problema y compararlo con la alternativa de clasificación.

Ejemplo de ello son las frecuentes revisiones de la literatura como la de Madan et al. (2020), quien destaca a las Redes de Neuronas Artificiales como la mejor aproximación para la predicción de contaminantes.

En 2018, Amado and Dela Cruz (2018) apostaron por el uso de sensores más económicos y fáciles de portar que los de los compuestos químicos originales para el AQI (incluyendo, al igual que nosotros, Temperatura y Humedad) para deducir la calidad del aire. Tras alimentar con estos datos a cinco modelos de AA, siendo tres de ellos objeto de nuestro estudio, obtuvieron unos excelentes resultados. Centrándonos en aquellos que nos incumben, las ANN lograrían una precisión del 99.56%, k-NN del 98.67% y las SVM un 97.78%. Sobre este último algoritmo, Amado y Dela Cruz recalcan el uso de un Kernel polinomial, notando un rendimiento superior en problemas con varios predictores, como el que nos concierne. Regresaremos a este punto más adelante.

No obstante, pese a haber usado otras métricas, Validación Cruzada (para evitar el overfitting) y LogLoss (para penalizar la seguridad con la que se clasifica una instancia erróneamente), lo más probable es que, al no haber aplicado ninguna técnica de balanceo, sus clases estuvieran desbalanceadas. Lo ideal habría sido utilizar medidas que evaluaran la relación entre las predicciones de pertenencia a una clase y la pertenencia real a la misma para cada clase por separado (como VPP, Sensibilidad, o F1-Macro).

Durante nuestro repaso de la literatura, fueron varios los *Papers* que, como el anterior, dejaban a la Precisión (*Accuracy*) como único indicador de calidad de los modelos. El equipo de Jirapattarasakul et al. (2025) identificó correctamente la necesidad de usar métricas robustas frente al desbalanceo, incluyendo las recientemente mencionadas. Sin embargo, en las conclusiones sobre los resultados, referencian casi exclusivamente la tasa global de acierto como métrica de calidad, dejando sólo las matrices de confusión como referencia.

En relación con la importancia de la rigurosidad en el análisis de resultados, tomemos como ejemplo la investigación de Vishwakarma et al. (2025) sobre algoritmos de regresión y clasificación para la predicción de la calidad del aire. En los gráficos de métricas de los modelos de clasificación (véase figura 6) se produce un fenómeno casi imposible en el ámbito del *Machine Learning*: Todas las métricas (Precisión, VPP, Sensibilidad, F1-Score, Kappa y F-Beta) pasan del 99.5%. Esto se debe a que los autores incluyeron columnas relativas a los índices AQI de cada contaminante. Como ya se discutió en la sección 1.2, el AQI final no es otra cosa que el máximo de entre los índices individuales. Es decir, el modelo simplemente está aprendiendo a devolver el mayor de esos valores.




Figure 6: Ejemplo de métricas sospechosamente perfectas con un Árbol de decisión.

En esta misma línea, volvamos a la selección de hiperparámetros de los modelos, concretamente el Kernel usado en las SVM. Handayani et al. (2021), abordando el mismo problema con sensores y SVM que Amado y Dela Cruz, probaron los 4 kernels con los que trabajaremos nosotros (Lineal, Gaussiano, Sigmoidal y Polinomial). En su caso, fue el Kernel Lineal, por bastante margen, el que mejores resultados dio, con nada menos que un resultado de 100% en Precisión, F1-Score y

Sensibilidad. Similar al caso anterior, esta SVM había sido únicamente probada sobre el conjunto de entrenamiento, por lo que dichos resultados, aunque interesantes, serían fruto de un fuerte sobreajuste.

La investigación de Hamami and Fithriyah (2020) sobre las ANN para la clasificación de la calidad del aire (siendo estas, recordemos, las que mejores resultados obtenían en este campo según la revisión de Madan), es un excelente ejemplo de la importancia de un ajuste exhaustivo de los hiperparámetros para comprobar sus efectos en métricas distintas. En su caso, descubrieron que un mayor número de capas en la red no implicaba sistemáticamente mejores resultados, sino que dependía de la combinación con el número de épocas y la métrica a observar.

Teniendo en cuenta la especial importancia de escoger y emplear adecuadamente las métricas y los hiperparámetros, pondremos especial énfasis en estos aspectos durante la fase de desarrollo.

Otro pilar del desarrollo de un estudio, y que merece especial atención, es la preparación de los datos, principalmente el preprocesamiento y la división del dataset para su validación. El Estado del Arte pone especial hincapié en el primer punto, como en el estudio realizado por Emeç and Yurtsever (2025) sobre el aire de Pekín y Estambul en 2025. Por ejemplo, estos autores decidieron dejar los valores atípicos, al poder tratarse de picos de contaminación reales que deben tenerse en cuenta. Tang et al. (2024) advertían de esto mismo en su exhaustivo repaso de los problemas más comunes que cometía la literatura de este ámbito, recomendando eliminar los atípicos siempre y cuando se tuviese la certeza de que son por errores en la medición.

El equipo de Emeç también abordó otro problema inherente al caso de estudio que nos concierne, la fuerte inconsistencia de escalas de valores entre variables tan dispares como la temperatura o la proporción de PM_{2.5}, y lo solucionaron con una estandarización sobre el conjunto de entrenamiento (para evitar fugas de datos al de test). La estandarización de los datos es fundamental en modelos que dependen de la geometría de los datos, como las SVM o k-NN, a diferencia de otros como los Árboles de Decisión. Aunque autores como Sasmita et al. (2024) optan por la estandarización, otros enfoques prefieren la normalización Min-Max para variables con distribuciones muy sesgadas y límites físicos rígidos (como el límite inferior de $0\mu g/m^3$ en contaminantes). Por ello, en nuestro desarrollo empírico adoptaremos la normalización Min-Max.

En cuanto a la división del dataset, el estándar que utilizaron el grueso de los autores, como los ya mencionados Vishwakarma, Jirapattarasakul, Hamami o Lee et al. (2020) en su aplicación del *Machine Learning* para el aire de Taiwán; fue una Validación Cruzada con $k = 5$ (80/20). Aunque teóricamente existen particiones más exhaustivas como $k = 10$, la literatura práctica consolida el $k = 5$ como el estándar empírico para datasets de tamaño medio. Por ello, adoptaremos este valor. Asimismo, aunque el equipo de Lee mencionaba explícitamente la aleatoriedad en la división de los k-conjuntos, para nuestro problema creemos imprescindible usar la versión estratificada de dicho método para evitar sesgos por el desbalanceo entre clases.

Cabe destacar el esfuerzo realizado en la búsqueda de literatura que emplease los mismos algoritmos seleccionados para este trabajo, con el fin de establecer un marco comparativo de rendimiento. Tras una exhaustiva revisión, no se ha hallado ninguna investigación previa que aplique el algoritmo de regresión simbólica DoME a la clasificación de la calidad del aire. Por ello, este estudio se fundamenta en el análisis del trabajo original de Daniel Rivero, Enrique Fernández Blanco y Alejandro Pazos (Rivero et al. (2022)), posicionándose como una propuesta pionera en la transposición de esta técnica determinista desde la regresión simbólica pura hacia un escenario de clasificación multiclase en el dominio medioambiental.

Table 3: Resumen de la revisión bibliográfica y su impacto metodológico en el presente estudio.

Referencia	Enfoque del Estudio	Lección Metodológica Aplicada en el Desarrollo
Rybarczyk (2018)	Revisión sistemática de IA en calidad del aire.	Justifica empíricamente la selección de ANN y SVM como los algoritmos predictivos predominantes en el estado del arte.
Madan et al. (2020)	Predicción de contaminantes mediante ML.	Confirma la idoneidad y superioridad de las Redes Neuronales (ANN) frente a métodos estadísticos clásicos.
Amado et al. (2018)	Uso de variables meteorológicas (Temp/Hum) con SVM/ANN.	Valida el uso de atributos climáticos como predictores indirectos fiables de la calidad del aire.
Jirapattarasakul (2025)	Comparativa Deep Learning vs Machine Learning clásico.	Resalta la necesidad crítica de analizar métricas por clase (F1-Score, Recall) frente al desbalanceo, en lugar de depender de la precisión global.
Vishwakarma (2025)	Regresión y Clasificación sobre niveles AQI.	Sirve como contraejemplo de <i>Data Leakage</i> (fuga de datos).
Handayani et al. (2021)	Evaluación de SVM con múltiples kernels.	Evidencia el riesgo de sobreajuste crítico (100% Acc) al no aplicar correctamente técnicas de validación cruzada.
Hamami et al. (2020)	Optimización arquitectónica de ANN.	Justifica la necesidad de explorar hiperparámetros mediante <i>Grid Search</i> en lugar de fijar topologías arbitrarias.
Emeç et al. (2025)	<i>Stacking Ensemble</i> en ciudades altamente contaminadas.	Fundamenta teóricamente la retención de valores atípicos, validándolos como picos reales de contaminación y no como ruido.
Tang et al. (2024)	Revisión crítica de errores metodológicos comunes en ML.	Refuerza la política restrictiva de limpieza de datos: eliminar instancias únicamente ante la violación de límites físicos.
Sasmita et al. (2024)	Comparativa k-NN vs Árboles de Decisión.	Demuestra la necesidad innegociable de escalar variables (Min-Max) para asegurar la convergencia en modelos geométricos.
Lee et al. (2020)	Previsión de calidad del aire mediante ML en Taiwán.	Establece empíricamente $k = 5$ como el estándar de partición para validación cruzada en este dominio de aplicación.

4 Desarrollo

4.1 Descripción

Como se ha mencionado anteriormente, la base de datos con la que se ha trabajado recoge un conjunto de observaciones medioambientales y demográficas descritas mediante 9 atributos numéricos continuos, cuya naturaleza se detalla en la sección 2.4.1 y cuyas estadísticas descriptivas se encuentran en la tabla 2. Dado que todos los atributos son de tipo numérico, no ha sido necesario aplicar técnicas de codificación como one-hot encoding sobre las entradas, lo que simplifica de forma considerable la fase de preprocesado.

Inicialmente, el dataset constaba de 5000 instancias. Sin embargo, como ya se advirtió en la sección 2.4.5, el análisis de los datos reveló la presencia de valores físicamente imposibles, como concentraciones negativas de contaminantes como SO_2 y PM_{10} , humedades relativas superiores al 100% o temperaturas ambientales que superan los 58°C , valores incompatibles con condiciones habitables en cualquier región y, por lo tanto, imposibles. Como estos valores son consecuencia directa del carácter parcialmente sintético del dataset incluirlos en el entrenamiento podría introducir ruido en los modelos y distorsionar lo aprendido, comprometiendo la validez de los resultados. Por este motivo, se ha optado por eliminar todas aquellas instancias que incumplan los límites físicos razonables que hemos establecido para cada atributo.

El análisis visual de la distribución de estos atributos, localizado en los histogramas de la Figura 2 y los diagramas de caja de la Figura 3, permite apreciar tanto el rango de valores de cada variable

como su relación con la variable objetivo. Estos aspectos han guiado las decisiones de preprocesado descritas a continuación.

4.1.1 Eliminación de instancias anómalas

El criterio de filtrado consiste en descartar toda instancia que presente al menos un atributo fuera del rango físicamente posible. Los límites aplicados para cada atributo para la eliminación de instancias anómalas se recogen en la Tabla 4.

Aunque se detectaron temperaturas superiores a 50°C de dudosa veracidad (como se indicó en la sección 2.4.5), se ha establecido un límite de corte conservador de 60°C para la limpieza automática, asegurando que solo se descartan valores estrictamente imposibles en la Tierra, delegando en los modelos la gestión de los extremos.

Table 4: Límites de filtrado aplicados por atributo para la eliminación de instancias anómalas.

Variable	Mínimo	Máximo
Temperatura (°C)	-30,00	60,00
Humedad (%)	0,00	100,00
PM2.5 ($\mu\text{g}/\text{m}^3$)	0,00	500,00
PM10 ($\mu\text{g}/\text{m}^3$)	0,00	500,00
NO ₂ (ppb)	0,00	200,00
SO ₂ (ppb)	0,00	200,00
CO (ppm)	0,00	50,00
Proximidad ind. (km)	0,00	100,00
Densidad pobl. (pers./km ²)	0,00	50.000,00

Tras aplicar este filtrado, se eliminaron 225 instancias del total original, quedando el conjunto de datos reducido a 4775 instancias, que son las empleadas en los experimentos. Esta reducción representa únicamente el 4,5% del total, por lo que el impacto sobre la representatividad del dataset es mínimo.

En cuanto a los atributos, no se ha eliminado ninguno de los 9 disponibles. Esta decisión se basa en que todos ellos presentan una relación potencialmente significativa con la calidad del aire, como se ilustró en los diagramas de caja y dispersión de la Figura 3. Eliminar variables como la densidad de población o la proximidad a zonas industriales supondría descartar información contextual que los modelos de aprendizaje automático pueden aprovechar para capturar relaciones que el AQI clásico no contempla, tal y como se argumentó en la sección 1.2. Además, ningún atributo presenta varianza nula tras el filtrado, por lo que tampoco existe ninguna razón técnica que justifique su eliminación.

En lo que respecta a la distribución de clases, el filtrado no altera de forma significativa el desbalanceo presente en el dataset original. La clase mayoritaria sigue siendo Good, que cuadruplica en tamaño a la clase minoritaria, Hazardous. Como ya se discutió en la sección 2.4.3, esto refuerza la necesidad de emplear métricas robustas al desbalanceo como el F1-score macro y el recall por clase en lugar de la accuracy global.

Razones para el rechazo de otros tratamientos de datos

A continuación se justifica el enfoque utilizado: la eliminación de valores de instancia físicamente imposibles, frente a otras técnicas de eliminación de valores atípicos más agresivas.

La Figura 3a muestra una gran cantidad de *outliers*, en prácticamente todas las variables. Dado que los modelos de aprendizaje automático utilizados en este trabajo, en particular SVM y k-NN, son sensibles a los valores atípicos, podría parecer coherente eliminarlos. No obstante, este enfoque plantea un problema fundamental: sería suficiente con que uno solo de los atributo de una instancia fuese anómalo para descartar la instancia completa. Y, como se observa en los diagramas de caja, la gran mayoría de *outliers* pertenece a las clases con valores extremos: calidad del aire *Peligroso* y *Pobre*.

Para comprobar esta hipótesis, se aplicó una de las técnicas de eliminación de valores atípicos más habituales: el rango intercuartílico (IQR). Tras eliminar todas las instancias con al menos un atributo fuera del rango $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$, se observó la distribución resultante de la variable objetivo:




Figure 7: Distribución de las clases de calidad del aire tras la eliminación de *outliers* mediante IQR.

El gráfico verifica la hipótesis: la distribución de la variable objetivo se ha vuelto considerablemente más desigual. La clase *Peligroso* ha quedado reducida a apenas un 2,14% del dataset, mientras que la clase *Bueno* ocupa aproximadamente la mitad. Utilizando esta distribución de los datos, aunque las métricas globales de clasificación fuesen aceptables, los modelos serían incapaces de clasificar correctamente instancias de calidad del aire peligrosas, al no contar con ejemplos suficientes de esta clase durante el entrenamiento.

Por el contrario, si se eliminan únicamente las instancias con valores físicamente imposibles, la distribución resultante es la siguiente:




Figure 8: Distribución porcentual de las clases tras el balanceo.

Se observa una distribución prácticamente idéntica a la original, con variaciones mínimas en todas las clases. Este enfoque conserva la representatividad de las clases minoritarias sin introducir instancias con valores que carecen de sentido físico.

No obstante, la distribución de clases resultante sigue siendo irregular. Aunque ha proporcionado resultados aceptables durante el entrenamiento, en la sección de trabajo futuro se discutirán técnicas de *resampling* que podrían paliar los efectos negativos de este desbalanceo.

4.1.2 Análisis exploratorio de datos

Un procedimiento estándar antes del preprocesado de datos es el análisis de las relaciones entre variables con el fin de buscar fuertes dependencias entre ellas que puedan justificar una reducción de la dimensionalidad, la coherencia de los datos, y otros aspectos interesantes a tener en cuenta.

Durante esta fase, se prestó especial atención a la relación entre los predictores particulados PM2.5 y PM10. El coeficiente de Pearson (véase Figura 9 arrojó una correlación casi perfecta ($r = 0.97$), lo cual es físicamente coherente dado que las partículas finas son, por definición, un subconjunto de las partículas de mayor diámetro. A pesar de que esta redundancia sugiere la eliminación de uno de los predictores para simplificar el modelo, se decidió mantener ambos. Esta elección se fundamenta en dos pilares: primero, la baja dimensionalidad del dataset (9 variables) no justifica el riesgo de pérdida de información (posible, pues no es una relación perfecta 1:1); segundo, se pretende extraer patrones sutiles de la interacción entre ambas variables, los cuales podrían ser críticos en la clasificación de episodios de contaminación extrema (clase 'Hazardous').




Figure 9: Mapa de calor de la correlación de Pearson entre variables meteorológicas, contaminantes y factores demográficos.

La matriz de correlación de Pearson, recogida en la Figura 9, permite cuantificar y matizar las observaciones visuales de la sección 2.4.6:

- **La ilusión visual de NO2 y SO2:** Mientras que en los diagramas de caja (Figura 3), analizados en dicha sección, ambos gases parecían presentar distribuciones casi idénticas, el análisis de Pearson revela una correlación de apenas 0.57. Esto demuestra empíricamente que, aunque escalan de forma similar frente al empeoramiento del aire, capturan fenómenos químicos subyacentes distintos, justificando su inclusión simultánea.
- **La huella industrial:** Se confirma matemáticamente la relación inversamente proporcional advertida en el análisis visual. La variable 'Proximidad a zonas industriales' presenta fuertes correlaciones negativas con los principales gases de combustión: CO (-0.71), NO2 (-0.60) y SO2 (-0.57). Esto garantiza que el dataset es físicamente coherente: a menor distancia a la industria, las concentraciones de gases tóxicos y la temperatura (-0.58) se disparan de forma acoplada.

4.1.3 Normalización de los datos

Como se ha detallado, se toman como entradas los nueve atributos numéricos originales. Para la implementación computacional de este estudio, se ha optado por aplicar una normalización Min-Max global sobre la totalidad del conjunto de datos filtrado antes de proceder a la validación cruzada.

Desde una perspectiva metodológica estricta, el cálculo de los parámetros x_{min} y x_{max} sobre el dataset completo introduce un nivel mínimo de transferencia de información (*data leakage*) desde el conjunto de prueba hacia el de entrenamiento. No obstante, esta decisión se justifica como un compromiso de diseño aceptable por dos motivos: en primer lugar, el volumen de muestras tras el filtrado ($N = 4775$) es lo suficientemente elevado como para que los estadísticos de cualquier pliegue de entrenamiento converjan casi idénticamente con los globales; y en segundo lugar, los límites físicos de las variables ambientales están fuertemente acotados, lo que minimiza el impacto de los valores atípicos en el escalado. Este procedimiento asegura la estabilidad en la convergencia de la Red Neuronal Artificial (ANN) manteniendo la integridad de las comparaciones entre modelos.

La Tabla 5 detalla los valores estadísticos reales del dataset filtrado empleados para proyectar las variables al rango $[0, 1]$ mediante la ecuación 6.

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (6)$$

Table 5: Parámetros estadísticos empíricos de normalización (mínimos y máximos reales del dataset filtrado) que sirven como referencia para los pliegues de validación.

Variable	Mínimo Empírico (x_{min})	Máximo Empírico (x_{max})
Temperatura ($^{\circ}C$)	13.40	58.60
Humedad (%)	36.00	100.00
PM2.5 ($\mu g/m^3$)	0.00	240.10
PM10 ($\mu g/m^3$)	0.00	261.50
NO_2 (ppb)	7.40	64.90
SO_2 (ppb)	0.00	42.30
CO (ppm)	0.65	3.67
Proximidad ind. (km)	2.50	25.80
Densidad pobl. ($pers./km^2$)	188.00	957.00

4.1.4 Metodología del experimento

Para evaluar el rendimiento de los distintos modelos de forma robusta y comparable, se ha empleado una validación cruzada estratificada de cinco folds.

La estratificación consiste en construir cada fold de manera que la proporción de instancias de cada clase refleje la del dataset completo. Así, si la clase Good representa el 40% de las instancias, en cada fold aproximadamente el 40% de las instancias de test pertenecerán a esa clase. Esto es especialmente relevante en datasets desbalanceados como este, donde una partición aleatoria sin estratificar podría generar folds con muy pocas o ninguna instancia de la clase minoritaria (Hazardous), imposibilitando una evaluación fiable del rendimiento en dicha clase.

De este modo, se garantiza que la proporción de instancias de cada clase se mantiene aproximadamente constante en cada partición, lo que es importante teniendo en cuenta el desbalanceo del dataset. Con un total de 4775 instancias y cinco folds, en cada iteración el 80% de los datos (aproximadamente 3820 instancias) se destina al entrenamiento, reservando el 20% restante (aproximadamente 955 instancias) para el conjunto de test.

Esta elección de $k=5$ responde a un compromiso entre sesgo y varianza: un valor de k más bajo (como $k = 2$) introduciría mayor sesgo al entrenar con menos datos (cada fold entrena con solo el 50% de los datos introduciendo más sesgo), mientras que un k más alto (como $k=10$ o leave-one-out) incrementaría el coste computacional sin proporcionar una mejora significativa en la estimación del error para un dataset de este tamaño.

Además, esta elección no es arbitraria, sino que, como observamos en la sección 3, sigue el estándar empírico establecido en la literatura para este tipo de investigaciones

Las métricas obtenidas en cada fold se promedian para obtener el resultado final, proporcionando además la desviación típica como indicador de la estabilidad del modelo frente a distintas particiones de los datos (cuánto varía el modelo de un fold a otro).

En el caso de las Redes de Neuronas Artificiales (ANN), el carácter no determinista del proceso de entrenamiento (derivado de la inicialización aleatoria de los pesos) exige promediar múltiples ejecuciones por fold. Sin embargo, tras un análisis preliminar de convergencia, se decidió ajustar este parámetro a cinco repeticiones por fold en lugar de las 50 habituales. Esta optimización es crucial para viabilizar el proyecto frente al elevado coste computacional de los algoritmos más exigentes: mientras que modelos geométricos (k-NN), de partición (Árboles de Decisión) o basados en hiperplanos (SVM) resuelven la validación cruzada en apenas unos segundos, la búsqueda de hiperparámetros para las Redes Neuronales y para la Regresión Simbólica (DoME), requiere tiempos de ejecución muy elevados. El tiempo requerido para la ejecución de DoME, dada la considerable profundidad de cada uno de los árboles, puede tomar incluso varias horas dependiendo del *hardware* de la máquina. Al reducir las repeticiones de la ANN a cinco, se observó que la varianza del F1-Score seguía siendo despreciable gracias al volumen del dataset, permitiéndonos destinar esos valiosos recursos computacionales (y de tiempo) a realizar una exploración más exhaustiva en la búsqueda en rejilla para todos los modelos.

4.1.5 Modelos e hiperparámetros (Búsqueda en rejilla)

Para garantizar una comparativa justa y exprimir el potencial de cada algoritmo, no se han evaluado configuraciones estáticas, sino que se ha implementado una búsqueda en rejilla (Grid Search) exhaustiva sobre el espacio de hiperparámetros de cinco aproximaciones distintas:

- **Máquinas de Vectores de Soporte (SVM):** Se configuró una búsqueda evaluando 12 combinaciones para comprobar cómo afecta el cambio de kernel y la regularización (C):
 - *Kernel Lineal:* Evaluado con $C \in \{0.1, 1.0, 10.0, 100.0\}$ para estudiar si el problema es linealmente separable.
 - *Kernel Gaussiano (RBF):* Se combinaron $C \in \{1.0, 10.0\}$ con el parámetro $\gamma \in \{0.1, 1.0\}$ para buscar fronteras de decisión no lineales.
 - *Kernel Polinómico:* Se fijó el grado a $d = 3$ (un valor estándar para evitar tiempos de ejecución muy altos y prevenir el sobreajuste) y $coef0 = 0.0$, variando $C \in \{1.0, 10.0\}$. Se incluyó este kernel específicamente para poner a prueba los excelentes resultados reportados por Amado and Dela Cruz (2018) bajo configuraciones polinómicas.
 - *Kernel Sigmoidal:* Se evaluó con $C \in \{1.0, 10.0\}$ y $coef0 = 0.0$.
- **K Nearest Neighbors (k-NN):** Para este clasificador basado en distancias (cuyo rendimiento aseguramos previamente mediante la normalización Min-Max, tal y como advierten Sasmita et al. (2024)), se probaron 8 valores distintos para el número de vecinos: $k \in \{3, 5, 7, 9, 11, 15, 21, 25\}$. Se eligieron valores impares para evitar empates en la votación mayoritaria.
- **Árboles de Decisión:** Para controlar la complejidad del árbol y evitar que memorice los datos (sobreajuste), se evaluaron 8 límites de profundidad máxima: $\{3, 5, 7, 10, 12, 15, 20, 25\}$.
- **Redes de Neuronas Artificiales (ANN):** Al ser uno de los algoritmos requeridos por el enunciado, se diseñó un espacio de búsqueda centrado en optimizar su topología. Se probaron 10 variantes distintas: cinco con una sola capa oculta $\{10, 20, 30, 40, 50\}$ y otras cinco con dos capas ocultas $\{[10, 5], [20, 10], [30, 15], [40, 20], [50, 25]\}$. Se descartó la exploración de arquitecturas más profundas (de tres o más capas) apoyándonos en las conclusiones de Hamami and Fithriyah (2020), quienes demostraron que en la clasificación de la calidad del aire, una mayor profundidad tiende a estancar el rendimiento predictivo y disparar el coste computacional. Para todas las topologías evaluadas, se fijó una arquitectura base utilizando la función de activación sigmoide (σ) en las capas ocultas y *softmax* en la capa de salida. El entrenamiento se llevó a cabo mediante el optimizador Adam con una tasa de aprendizaje (*learning_rate*) constante de 0.01, minimizando la función de pérdida de entropía cruzada categórica durante un límite máximo de 1000 épocas por ejecución.

- **DoME:** Para este algoritmo se siguió una estrategia de búsqueda en dos fases. En una exploración preliminar amplia se barrió el dominio $\{5, 10, 15, 20, 25, 30, 40, 50, 75, 100\}$, observando una tendencia creciente del F1-Score conforme aumentaba el número de nodos, lo que sugería que la región óptima se encontraba en el extremo superior del intervalo. A raíz de este hallazgo, se realizó una segunda búsqueda en rejilla centrada en torno a dicha región, evaluando 10 configuraciones controlando el número máximo de nodos permitidos en los árboles de expresiones: $\{75, 90, 100, 110, 125, 140, 150, 165, 180, 200\}$. Esta búsqueda focalizada permite caracterizar con mayor precisión el comportamiento del algoritmo en el intervalo donde se obtienen los mejores resultados.

4.2 Resultados

A continuación, se presenta la evaluación empírica de los cinco modelos de clasificación desarrollados. El objetivo de esta sección es determinar la configuración óptima para cada algoritmo y analizar su capacidad para modelar la calidad del aire.

Para garantizar que las conclusiones sean robustas y representativas de la capacidad de generalización de los modelos, todas las métricas expuestas en esta sección se han calculado exclusivamente sobre el conjunto de test durante el proceso de validación cruzada estratificada de 5 pliegues ($k = 5$). En cada tabla de resultados del *Grid Search*, se reporta el F1-Score medio acompañado de su desviación típica (*std*), lo que permite evaluar no solo el acierto bruto, sino la estabilidad del modelo frente a diferentes particiones de los datos de entrenamiento. Posteriormente, para la mejor configuración de cada algoritmo, se desglosan las métricas por clase y su respectiva matriz de confusión agregada para estudiar su comportamiento frente al desbalanceo.

Como aclaración, debido a la alta demanda computacional exigida por la exploración de hiperparámetros (*Grid Search*), especialmente en modelos de aprendizaje profundo como las ANN, se implementó un esquema de aceleración por hardware mediante el uso explícito de la arquitectura **CUDA**.

4.2.1 Máquinas de Vectores de Soporte (SVM)

Para el entrenamiento de las SVM, se definió un espacio de búsqueda que combinaba distintos niveles de regularización (parámetro C) con cuatro transformaciones del espacio de características (kernels). La Tabla 6 muestra los resultados de las 12 configuraciones evaluadas.

Table 6: Resultados de la búsqueda en rejilla para SVM sobre el conjunto de test.

Hiperparámetros	F1 Medio	Desv. Típica (std)	Accuracy	Precision	Recall
kernel=rbf, $C=10.0$, $\gamma=1.0$	0.9470	0.0089	0.9476	0.9473	0.9476
kernel=linear, $C=100.0$	0.9430	0.0073	0.9437	0.9434	0.9437
kernel=rbf, $C=1.0$, $\gamma=1.0$	0.9416	0.0074	0.9426	0.9420	0.9426
kernel=linear, $C=10.0$	0.9399	0.0061	0.9407	0.9401	0.9407
kernel=rbf, $C=10.0$, $\gamma=0.1$	0.9376	0.0065	0.9386	0.9378	0.9386
kernel=sigmoid, $C=10.0$	0.9375	0.0048	0.9386	0.9379	0.9386
kernel=linear, $C=1.0$	0.9364	0.0043	0.9376	0.9370	0.9376
kernel=rbf, $C=1.0$, $\gamma=0.1$	0.9297	0.0071	0.9315	0.9313	0.9315
kernel=sigmoid, $C=1.0$	0.9199	0.0093	0.9234	0.9249	0.9234
kernel=linear, $C=0.1$	0.9173	0.0106	0.9208	0.9222	0.9208
kernel=poly, $C=10.0$, $d=3$	0.8814	0.0094	0.8846	0.8837	0.8846
kernel=poly, $C=1.0$, $d=3$	0.5242	0.0058	0.5833	0.5737	0.5833

El análisis de la tabla revela contrastes muy marcados dependiendo del kernel seleccionado. La configuración óptima resultó ser el kernel Gaussiano (RBF) con una regularización estricta ($C = 10.0$) y un parámetro $\gamma = 1.0$, logrando el F1-Score más alto de todo el estudio (0.9470). Curiosamente, el kernel lineal también obtuvo resultados sobresalientes ($F1 = 0.9430$ con $C = 100.0$). Por el contrario, el kernel polinómico de grado 3 obtuvo los peores resultados del estudio, con un F1 de 0.5242 para $C = 1.0$ y de 0.8814 para $C = 10.0$. Como se mencionó en la sección 3, este resultado contradice las expectativas generadas por algunos autores que reportaron un rendimiento superior

con este kernel en un problema similar. Esto demuestra que al aplicar un escalado Min-Max estricto, la proyección a espacios polinómicos añade una varianza perjudicial para la clasificación.

A continuación, se detalla el comportamiento de la configuración ganadora (RBF, $C = 10.0$, $\gamma = 1.0$) mediante el desglose de métricas por clase y su matriz de confusión (Tabla 7).

Table 7: Métricas por clase y Matriz de Confusión agregada (SVM: RBF, $C=10.0$, $\gamma=1.0$).

Clase	Precision	Recall	F1	Real \ Pred	Mod.	Good	Haz.	Poor
Good	0.995	0.999	0.997	Moderate	1445	9	0	39
Moderate	0.944	0.968	0.956	Good	2	1981	0	0
Poor	0.875	0.867	0.871	Hazardous	0	0	293	76
Hazardous	0.880	0.794	0.835	Poor	84	0	40	806

A pesar de tratarse del modelo con mayor F1-Score global, la SVM presenta el mismo patrón de dificultad frente al desbalanceo que el resto de algoritmos. Muestra una precisión casi perfecta aislando la clase mayoritaria (*Good*), pero la sensibilidad (*Recall*) en la clase minoritaria (*Hazardous*) desciende al 0.794. La matriz de confusión indica que el modelo clasifica erróneamente 76 instancias reales de aire *Hazardous* como *Poor*, subestimando la gravedad de la contaminación en esos casos críticos. Aún así, es el algoritmo (junto con la Red Neuronal) que mejor logra mitigar este solapamiento entre las dos clases más severas.

A continuación se presentan los resultados obtenidos para los distintos modelos evaluados. Las métricas mostradas corresponden al promedio de los 5 folds de la validación cruzada, incluyendo su desviación típica como medida de estabilidad.

Para visualizar la estabilidad estadística de los distintos kernels y penalizaciones evaluadas, la Figura 10 representa el F1-Score medio junto con su margen de error (desviación típica inter-fold). Se aprecia gráficamente la superioridad de los kernels RBF y Lineal frente a la alta inestabilidad del kernel polinómico de grado 3.




Figure 10: Comparativa estadística del F1-Score para las configuraciones de SVM evaluadas.

4.2.2 Árboles de Decisión

El algoritmo de Árboles de Decisión (DT) destaca por su interpretabilidad y su naturaleza no paramétrica. Durante la fase experimental, cuya validación cruzada se completó de forma muy eficiente, se evaluaron 8 configuraciones variando el límite de profundidad máxima. Este parámetro actúa como mecanismo de poda a priori, crucial para controlar la complejidad estructural y prevenir el sobreajuste. La Tabla 8 resume los resultados obtenidos en el espacio de búsqueda.

Los resultados evidencian el clásico compromiso entre sesgo y varianza. El rendimiento óptimo se alcanza con una profundidad de 10 niveles ($F1 = 0.9263 \pm 0.0105$). Las topologías excesivamente

Table 8: Resultados de la búsqueda en rejilla para Árboles de Decisión sobre conjunto de test.

Hiperparámetros	F1 Medio	Desv. Típica (std)	Accuracy	Precision	Recall
max_depth=10	0.9263	0.0105	0.9269	0.9268	0.9269
max_depth=12	0.9258	0.0085	0.9263	0.9259	0.9263
max_depth=7	0.9250	0.0062	0.9254	0.9261	0.9254
max_depth=15	0.9228	0.0092	0.9231	0.9234	0.9231
max_depth=20	0.9226	0.0093	0.9229	0.9232	0.9229
max_depth=25	0.9225	0.0093	0.9229	0.9232	0.9229
max_depth=5	0.9145	0.0097	0.9158	0.9182	0.9158
max_depth=3	0.8937	0.0101	0.8970	0.8992	0.8970

simples ($max_depth=3$) carecen de capacidad para resolver la no linealidad del problema, cayendo a un F1 de 0.8937. Por contra, expansiones superiores a 15 niveles no aportan ganancia predictiva y, de hecho, reducen marginalmente el rendimiento en test, al inducir cierto sobreajuste.

Table 9: Métricas por clase y Matriz de Confusión agregada (Árbol de Decisión, $max_depth=10$).

Clase	Precision	Recall	F1	Real \ Pred	Mod.	Good	Haz.	Poor
Good	0.993	0.993	0.993	Moderate	1420	14	1	58
Moderate	0.931	0.951	0.941	Good	14	1969	0	0
Poor	0.836	0.816	0.826	Hazardous	0	0	278	91
Hazardous	0.777	0.753	0.765	Poor	92	0	79	759

Analizando la configuración ganadora a nivel de clases (Tabla 9), observamos el impacto del desbalanceo. Mientras que la clase mayoritaria (*Good*) roza la clasificación perfecta, la métrica desciende drásticamente en los extremos anómalos. La matriz de confusión ilustra el error principal: el modelo presenta una fuerte confusión en las fronteras de decisión adyacentes, llegando a clasificar 91 muestras reales de aire *Hazardous* como meramente *Poor*, lo que reduce la sensibilidad en la clase más crítica al 0.753.

La Figura 11 ilustra gráficamente la evolución estadística del rendimiento frente al límite de profundidad. Se observa una clara estabilización a partir de $max_depth=10$, evidenciando que dotar al árbol de mayor libertad estructural no aporta beneficio predictivo y aumenta el riesgo de sobreajuste.




Figure 11: Evolución estadística del F1-Score en función de la profundidad del árbol.

4.2.3 K-Nearest Neighbors (k-NN)

Para evaluar el clasificador basado en instancias k-NN (cuyo coste tiempo de ejecución fue el más bajo de todo el experimento), se procedió a estudiar 8 configuraciones distintas. Para asegurar que la asignación de clase mediante voto mayoritario fuese determinista y no sujeta a resolución aleatoria de empates, se utilizaron exclusivamente valores impares para el tamaño del "vecindario" (k).

Table 10: Resultados de la búsqueda en rejilla para k-NN sobre conjunto de test.

Hiperparámetros	F1 Medio	Desv. Típica (std)	Accuracy	Precision	Recall
k=15	0.9278	0.0110	0.9303	0.9304	0.9303
k=9	0.9262	0.0079	0.9284	0.9277	0.9284
k=11	0.9260	0.0108	0.9284	0.9276	0.9284
k=5	0.9252	0.0081	0.9275	0.9259	0.9275
k=21	0.9243	0.0112	0.9271	0.9273	0.9271
k=7	0.9238	0.0091	0.9263	0.9256	0.9263
k=25	0.9201	0.0098	0.9231	0.9230	0.9231
k=3	0.9196	0.0109	0.9217	0.9200	0.9217

El hiperparámetro óptimo recayó en $k = 15$ ($F1 = 0.9278 \pm 0.0110$). El análisis de esta rejilla muestra una curva de rendimiento convexa muy representativa de los modelos geométricos. Valores excesivamente bajos ($k = 3$) generan fronteras de decisión altamente sensibles al ruido local. Por otro lado, al incrementar demasiado el tamaño del vecindario ($k \geq 21$), el F1-Score vuelve a descender. Esto ocurre porque el espacio de características proyectado (previamente normalizado con Min-Max) está fuertemente desbalanceado: vecindarios demasiado amplios provocan que las clases densas influyan a las instancias aisladas de clases menos frecuentes.

Table 11: Métricas por clase y Matriz de Confusión agregada (k-NN, k=15).

Clase	Precision	Recall	F1	Real \ Pred	Mod.	Good	Haz.	Poor
Good	0.982	1.000	0.991	Moderate	1443	37	0	13
Moderate	0.914	0.967	0.939	Good	0	1983	0	0
Poor	0.844	0.837	0.840	Hazardous	0	0	238	131
Hazardous	0.937	0.645	0.764	Poor	136	0	16	778

Esta limitación topológica se refleja críticamente en las métricas desglosadas (Tabla 11). Aunque el k-NN supera marginalmente al Árbol de Decisión en las métricas globales, su comportamiento frente a la clase *Hazardous* es nefasto, la sensibilidad baja a 0.645. La matriz de confusión explica matemáticamente este fallo: 131 casos reales de aire peligroso se encontraban geoméricamente rodeados por instancias *Poor*, perdiendo la votación mayoritaria de 15 vecinos y resultando en un alto volumen de falsos negativos.

Como complemento a la tabla, la Figura 12 muestra la dispersión del F1-Score según el tamaño del vecindario (k). La gráfica revela un pico de rendimiento en $k = 15$, demostrando el punto óptimo entre el ruido local (vecindarios muy pequeños) y la dilución por desbalanceo (vecindarios muy amplios).

4.2.4 Regresión Simbólica (DoME)

El algoritmo DoME (usado para regresión simbólica multiclase) representa un enfoque radicalmente distinto a los anteriores, buscando construir una expresión matemática explícita que relacione las entradas con la salida. Su validación cruzada resultó ser la más costosa computacionalmente de todo el experimento. Para controlar la complejidad de la ecuación generada y prevenir el sobreajuste, la búsqueda en rejilla limitó el número máximo de nodos del árbol de expresiones en 10 niveles distintos, concentrados en el intervalo donde la exploración preliminar había mostrado los mejores resultados (entre 75 y 200 nodos). Los resultados se recogen en la Tabla 12.




Figure 12: Evolución estadística del F1-Score según el número de vecinos (k).

Table 12: Resultados de la búsqueda en rejilla para DoME sobre conjunto de test.

Hiperparámetros	F1 Medio	Desv. Típica (std)	Accuracy	Precision	Recall
maximumNodes=180	0.9401	0.0072	0.9414	0.9416	0.9414
maximumNodes=200	0.9397	0.0051	0.9409	0.9413	0.9409
maximumNodes=165	0.9395	0.0086	0.9409	0.9412	0.9409
maximumNodes=140	0.9381	0.0107	0.9397	0.9401	0.9397
maximumNodes=125	0.9367	0.0109	0.9382	0.9386	0.9382
maximumNodes=150	0.9367	0.0118	0.9382	0.9385	0.9382
maximumNodes=100	0.9361	0.0107	0.9380	0.9387	0.9380
maximumNodes=110	0.9347	0.0076	0.9366	0.9374	0.9366
maximumNodes=90	0.9310	0.0090	0.9330	0.9332	0.9330
maximumNodes=75	0.9253	0.0104	0.9278	0.9290	0.9278

Tras la búsqueda focalizada en el intervalo donde se obtienen los mejores resultados, se observa que el rendimiento de DoME alcanza un máximo en `maximumNodes=180` ($F1 = 0.9401 \pm 0.0072$), formando una meseta estadísticamente equivalente entre las configuraciones superiores a 140 nodos. Es especialmente relevante que el rendimiento no continúa creciendo al pasar de 180 a 200 nodos, sino que se estabiliza o incluso decrece ligeramente, lo que sugiere haber localizado correctamente la región óptima del hiperparámetro. Por debajo de 100 nodos comienza a observarse una degradación progresiva, con la peor configuración del intervalo evaluado (75 nodos) descendiendo a $F1 = 0.9253$. La estrecha desviación típica del óptimo (0.0072) confirma además que la configuración de 180 nodos es la más estable de todo el barrido.

Table 13: Métricas por clase y Matriz de Confusión agregada (DoME, `maximumNodes=180`).

Clase	Precision	Recall	F1	Real \ Pred	Mod.	Good	Haz.	Poor
Good	0.993	0.996	0.995	Moderate	1449	12	0	32
Moderate	0.938	0.971	0.954	Good	5	1975	1	2
Poor	0.855	0.870	0.862	Hazardous	4	0	262	103
Hazardous	0.885	0.710	0.788	Poor	87	1	33	809

A pesar del buen rendimiento global, el análisis detallado de DoME (Tabla 13) revela que sufre del mismo sesgo que k-NN, aunque atenuado respecto a configuraciones con menor capacidad expresiva. La clase minoritaria *Hazardous* presenta una precisión alta (0.885) pero una sensibilidad todavía insuficiente (0.710). La matriz de confusión ilustra cómo 103 registros de aire extremadamente

tóxico fueron predichos a la baja como *Poor*, lo que indica que las ecuaciones generadas continúan tendiendo a los valores esperados de las clases con mayor soporte estadístico, si bien la mayor libertad paramétrica permite recuperar 18 instancias adicionales de *Hazardous* respecto a configuraciones más restringidas.

La Figura 13 representa la evolución del F1-Score en función del límite de nodos de las ecuaciones generadas. El gráfico evidencia el patrón descrito: una fase de crecimiento entre 75 y 140 nodos, seguida de una meseta de rendimiento entre 140 y 200 nodos con un máximo identificable en 180. La franja sombreada de la desviación típica muestra además que la variabilidad entre folds se reduce notablemente en la región óptima, reforzando la elección de `maximumNodes=180` como configuración final.




Figure 13: Evolución estadística del F1-Score respecto a la longitud máxima de la expresión (DoME).

4.2.5 Redes de Neuronas Artificiales (ANN)

Finalmente, para las Redes Neuronales Artificiales se exploraron 10 topologías distintas, combinando arquitecturas de una capa oculta con configuraciones profundas de dos capas. Al poseer un proceso de entrenamiento no determinista, la evaluación requirió promediar 5 repeticiones independientes por cada uno de los 5 *folds* de validación, pero sin consumir tanto tiempo como en las pruebas iniciales (donde se efectuaban 50 ejecuciones).

Table 14: Resultados de la búsqueda en rejilla para ANN sobre conjunto de test.

Hiperparámetros	F1 Medio	Desv. Típica (std)	Accuracy	Precision	Recall
topo=[50, 25]	0.9438	0.0089	0.9444	0.9439	0.9444
topo=[40, 20]	0.9434	0.0082	0.9441	0.9437	0.9441
topo=[20, 10]	0.9428	0.0083	0.9435	0.9431	0.9435
topo=[30, 15]	0.9424	0.0083	0.9430	0.9427	0.9430
topo=[10, 5]	0.9420	0.0073	0.9426	0.9422	0.9426
topo=[50]	0.9419	0.0075	0.9425	0.9421	0.9425
topo=[30]	0.9416	0.0076	0.9421	0.9418	0.9421
topo=[40]	0.9416	0.0074	0.9421	0.9417	0.9421
topo=[20]	0.9408	0.0076	0.9414	0.9410	0.9414
topo=[10]	0.9401	0.0082	0.9407	0.9403	0.9407

A diferencia de las acentuadas diferencias observadas en DoME o las SVM polinómicas, la ANN demuestra una asombrosa estabilidad frente a la variación paramétrica. Todas las topologías evaluadas oscilan en una franja de error muy estrecha, manteniéndose sistemáticamente por encima de 0.94 de F1-Score global. La arquitectura ganadora es la topología profunda [50, 25], validando empíricamente

que la inclusión de una segunda capa oculta proporciona las transformaciones no lineales necesarias para acotar mejor las fronteras. No obstante, topologías mucho más ligeras como [20, 10] rinden a escasas milésimas de distancia.

Table 15: Métricas por clase y Matriz de Confusión agregada (ANN, topología [50, 25]).

Clase	Precision	Recall	F1	Real \ Pred	Mod.	Good	Haz.	Poor
Good	0.994	0.997	0.996	Moderate	1439	11	0	43
Moderate	0.942	0.964	0.953	Good	5	1978	0	0
Poor	0.871	0.860	0.865	Hazardous	0	0	294	75
Hazardous	0.860	0.796	0.827	Poor	83	0	48	799

El análisis interno (Tabla 15) proclama a la ANN, junto con la SVM de kernel Gaussiano, como las arquitecturas predictivas más fiables del estudio. Consigue mitigar considerablemente la ceguera algorítmica frente al desbalanceo, elevando el *Recall* de la clase *Hazardous* a casi un 0.80. La matriz de confusión (cuyos valores promediados se han redondeado al entero más próximo para mayor claridad) denota que, aunque todavía existe confusión en fronteras adyacentes (75 falsos negativos hacia la clase *Poor*), la red neuronal modeliza la gravedad de la contaminación de forma mucho más robusta que algunos de los métodos anteriores.

Para verificar la asombrosa estabilidad observada en las Redes Neuronales, la Figura 14 compara estadísticamente el rendimiento de las arquitecturas evaluadas. Las barras de error ilustran que, aunque la topología profunda [50, 25] obtiene la mejor media empírica, la alta superposición de las desviaciones típicas confirma que el algoritmo encuentra mínimos locales de calidad muy similar independientemente de la complejidad de sus capas ocultas.




Figure 14: Comparativa estadística del F1-Score entre las distintas arquitecturas ocultas de la Red Neuronal Artificial.

4.3 Discusión

Los resultados obtenidos en la fase experimental nos han permitido extraer conclusiones tanto sobre el rendimiento individual de cada modelo como sobre el comportamiento colectivo del sistema. Esta sección analiza dichos resultados, contrastándolos entre sí y apoyándose en evidencias estadísticas para determinar qué algoritmo resuelve mejor el problema de clasificación a tratar.

4.3.1 Comparativa global de modelos

La Tabla 16 resume el rendimiento óptimo de cada modelo en su mejor configuración de hiperparámetros y su comportamiento medido mediante el recall en los casos más críticos (clases minoritarias).

Table 16: Comparativa global de los cinco modelos en su configuración óptima.

Modelo	Configuración óptima	F1 Medio	Desv. Típica	Recall Hazardous	Recall Poor
SVM	RBF, C=10.0, $\gamma=1.0$	0.9470	0.0089	0.794	0.867
ANN	topo=[50, 25]	0.9438	0.0089	0.796	0.860
DoME	maximumNodes=180	0.9401	0.0072	0.710	0.870
k-NN	k=15	0.9278	0.0110	0.645	0.837
DT	max_depth=10	0.9263	0.0105	0.753	0.816

A grandes rasgos, todos los modelos superan el umbral de 0.92 de F1-Score macro, lo que indica que el problema está bien estructurado y que los nueve atributos contienen información suficiente para discriminar correctamente entre las cuatro categorías. Sin embargo, las diferencias en el comportamiento frente a las clases minoritarias (especialmente *Hazardous*), como se muestra en la tabla, son notables y merecen un análisis detallado.

4.3.2 Impacto del desbalanceo de clases

Como se ha evidenciado en el análisis individual, la degradación del rendimiento en la clase *Hazardous* es un fenómeno transversal a todos los modelos. Según los resultados consolidados (Figura 15), el *Recall* en esta clase crítica oscila entre un mínimo de 0.645 (k-NN) y un máximo de 0.796 (ANN). Esta brecha de rendimiento respecto a la clase mayoritaria *Good* (donde todos los modelos superan el 0.993) no es una anomalía estadística, sino la consecuencia directa del desbalanceo documentado en la sección 2.4.3.

Esta limitación técnica tiene implicaciones directas en la seguridad pública. Un error al clasificar aire peligroso como *Moderate* o *Poor* constituye un falso negativo de alto coste social, ya que omitiría alertas sanitarias críticas. La Figura 15 ilustra visualmente esta "escalera de rendimiento": mientras que las clases mayoritarias presentan barras casi saturadas, la clase *Hazardous* revela la verdadera jerarquía de los algoritmos frente a datos minoritarios.




Figure 15: Comparativa del *Recall* por clase para los cinco modelos optimizados. Se observa la marcada caída en la clase *Hazardous*, especialmente crítica en el modelo k-NN.

Resulta especialmente revelador el comportamiento del modelo k-NN ($k = 15$). A pesar de tener una precisión competitiva, su sensibilidad en la clase *Hazardous* es la más baja del estudio (0.645). El motivo reside en la mecánica de voto mayoritario del algoritmo: en las zonas fronterizas entre *Poor* (clase con 20% de soporte) y *Hazardous* (10%), los 15 vecinos más cercanos de una instancia realmente peligrosa tienden a ser mayoritariamente de clase *Poor*. Esto provoca que el modelo

"ignore" la presencia de contaminación extrema si esta no es localmente dominante, resultando en 131 casos reales de aire peligroso clasificados erróneamente como *Poor*.

Por el contrario, el modelo DoME ($n = 180$) logra romper esta inercia geométrica, alcanzando un *Recall* de 0.710. Aunque sigue por debajo de las redes neuronales, su capacidad para construir expresiones matemáticas complejas le permite identificar patrones de toxicidad que escapan a la densidad local del k-NN. Finalmente, la SVM y la ANN se consolidan como las soluciones más robustas (rozando el 0.80 de *Recall*). Al generar fronteras de decisión no lineales que priorizan la separación de márgenes (SVM) o el aprendizaje de representaciones jerárquicas (ANN), logran mitigar parcialmente el sesgo del dataset, ofreciendo una protección significativamente superior en episodios de contaminación crítica.

4.3.3 Análisis de las matrices de confusión agregadas

Un análisis comparativo de las matrices de confusión de los cinco modelos revela un patrón de error: la principal fuente de confusión no es entre clases distantes (por ejemplo, predecir *Good* cuando la instancia es *Hazardous*), sino entre clases adyacentes en la escala de contaminación. Concretamente, los errores se concentran en la frontera *Hazardous–Poor* y en la frontera *Moderate–Poor*.

Table 17: Número de instancias *Hazardous* clasificadas erróneamente como *Poor* para cada modelo.

Modelo	Haz. → Poor (FN)	% sobre total Hazardous
k-NN	131	35.5%
DoME	103	27.9%
DT	91	24.7%
SVM	76	20.6%
ANN	75	20.3%

La Tabla 17 muestra el error más crítico del sistema: instancias de aire realmente peligroso clasificadas como pobre. El k-NN y DoME presentan las tasas más altas de este error (35.5% y 27.9% respectivamente), mientras que SVM y ANN lo reducen a aproximadamente 1 de cada 5 instancias. Esta diferencia, aunque pueda parecer pequeña en términos absolutos, tiene implicaciones directas en el número de alertas sanitarias omitidas en la aplicación de los modelos en un escenario real de monitorización de la calidad del aire.

Es también destacable que ningún modelo comete el error inverso de forma significativa: no se observan instancias *Good* clasificadas como *Hazardous* en ninguna de las matrices. Esto confirma que la separación entre los extremos está bien definida por todos los algoritmos, y que el problema real reside en la discriminación de las clases intermedias y en la detección, de forma fiable, de la clase minoritaria extrema.

4.3.4 Análisis de la estabilidad

La desviación típica entre folds aporta información valiosa sobre la robustez de cada modelo frente a distintas particiones de los datos.

Cabe destacar que la ANN y la SVM presentan la misma desviación típica (0.0089), pero por razones distintas. En la ANN, esta estabilidad es especialmente notable dado el carácter no determinista del entrenamiento: incluso con solo 5 repeticiones por fold, la varianza es comparable a la de la SVM, que es un modelo completamente determinista. Esto sugiere que el volumen del dataset (4775 instancias) es suficiente para que la validación cruzada estratificada compense la aleatoriedad del proceso de entrenamiento.

El Árbol de Decisión (0.0105) y el k-NN (0.0110) presentan las desviaciones típicas más altas, lo que indica que su rendimiento es más dependiente de la partición concreta que les toca en cada fold. En el caso del Árbol de Decisión, esto es coherente con su sensibilidad a pequeñas variaciones en los datos de entrenamiento, al poder alterar significativamente la estructura del árbol resultante. En k-NN, la variabilidad refleja que la composición del vecindario cambia con cada partición, afectando especialmente a las instancias frontera entre clases.

DoME presenta una desviación típica de 0.0072 en su configuración óptima, situándose entre los modelos más estables del estudio, a la par de SVM y ANN. Esta robustez es destacable ya que, al tratarse de un algoritmo de regresión simbólica, el espacio de búsqueda de expresiones matemáticas es enormemente amplio y, en principio, distintas particiones de los datos podrían llevar al algoritmo a explorar regiones diferentes de dicho espacio. La baja variabilidad observada en la región óptima del hiperparámetro (configuraciones entre 165 y 200 nodos) sugiere que, una vez se otorga suficiente libertad paramétrica, el algoritmo converge consistentemente hacia expresiones de capacidad predictiva equivalente independientemente del fold de validación.

4.3.5 Análisis del espacio de hiperparámetros

Una observación transversal de los resultados de la búsqueda en rejilla revela diferencias importantes en la sensibilidad de los modelos a sus hiperparámetros.

La ANN es el modelo más robusto frente a la variación de hiperparámetros: todas las topologías evaluadas se mantienen en una franja de apenas 0.004 de F1-Score (entre 0.9401 y 0.9438). Esta estabilidad sugiere que el algoritmo converge a soluciones de calidad similar independientemente de la complejidad de la arquitectura, siempre que esta supere un umbral mínimo. En la práctica, esto implica que no es necesario un ajuste fino exhaustivo de la topología para obtener buenos resultados con este dataset, y que modelos más ligeros como [20, 10] ofrecen un compromiso coste-rendimiento bastante favorable.

La SVM muestra el comportamiento más heterogéneo entre kernels. Como se anunció en la sección 3, Amado and Dela Cruz (2018) reportaron un rendimiento superior con el kernel polinómico en un caso similar al que es objeto de nuestro estudio. Sin embargo, nuestros resultados contradicen esta observación: el kernel polinómico de grado 3 obtiene un F1 de apenas 0.5242 para $C = 1.0$ y 0.8814 para $C = 10.0$, siendo con diferencia el peor kernel evaluado. Una diferencia metodológica relevante entre ambos estudios es el preprocesado aplicado, que podría explicar parcialmente esta discrepancia, como la normalización Min-Max que nosotros hemos aplicado. Por el contrario, el kernel RBF con $C = 10.0$ y $\gamma = 1.0$ obtuvo el mejor resultado global del estudio ($F1 = 0.9470$), seguido del kernel lineal con $C = 100.0$ ($F1 = 0.9430$).

Por otro lado, DoME muestra una sensibilidad moderada al hiperparámetro en el intervalo evaluado: el rango de F1-Score oscila entre 0.9253 (75 nodos) y 0.9401 (180 nodos), una diferencia de 0.0148. Cabe destacar que la búsqueda preliminar en el dominio amplio (de 5 a 100 nodos) sí había revelado una alta sensibilidad del algoritmo, con configuraciones de pocos nodos sufriendo *underfitting* severo. Sin embargo, una vez localizada e investigada la región óptima del hiperparámetro mediante la búsqueda focalizada, se observa que el modelo presenta una meseta de rendimiento estable a partir de los 140 nodos. La identificación de un máximo en 180 nodos (con descenso posterior en 200) confirma que se ha localizado correctamente el óptimo y descarta la hipótesis inicial de que valores aún mayores pudieran mejorar el rendimiento.

La Tabla 18 cuantifica la sensibilidad de cada modelo a sus hiperparámetros mediante el rango de F1-Score observado entre la mejor y la peor configuración evaluada.

Table 18: Sensibilidad al hiperparámetro: rango de F1-Score entre la mejor y peor configuración evaluada en la búsqueda en rejilla.

Modelo	F1 máximo	F1 mínimo	Rango	Nº configs.
SVM	0.9470	0.5242	0.4228	12
DoME	0.9401	0.9253	0.0148	10
DT	0.9263	0.8938	0.0326	8
k-NN	0.9278	0.9196	0.0082	8
ANN	0.9438	0.9401	0.0037	10

Los datos revelan una clara separación entre modelos según la sensibilidad mostrada en sus respectivas búsquedas. La SVM destaca con un rango superior a 0.42, lo que indica que una elección inadecuada del kernel y sus parámetros puede llevar al modelo desde un rendimiento competitivo hasta uno prácticamente aleatorio. El resto de modelos (ANN, k-NN, Árbol de Decisión y DoME en su intervalo refinado) muestran rangos inferiores a 0.033, siendo la ANN el modelo más robusto con apenas 0.0037 de diferencia entre su mejor y peor configuración. Conviene matizar que el bajo rango

observado en DoME corresponde a la segunda fase de búsqueda focalizada en el intervalo óptimo; la exploración preliminar amplia (de 5 a 100 nodos) sí evidenció una alta sensibilidad del algoritmo a configuraciones con escasa libertad paramétrica.

4.3.6 Contraste con el Estado del Arte

Los resultados obtenidos son coherentes con las referencias bibliográficas revisadas en la sección 3. La superioridad de SVM y ANN sobre k -NN y Árboles de Decisión confirma las observaciones de Rybarczyk and Zalakeviciute (2018), quienes identificaron estos dos algoritmos como los más utilizados y efectivos en el ámbito de la calidad del aire. Asimismo, los valores de F1-Score obtenidos (entre 0.926 y 0.947) son comparables a los reportados por Amado and Dela Cruz (2018) en datasets similares, aunque la comparación es limitada al tratarse de datasets distintos y al haber empleado métricas diferentes.

Un punto de contraste relevante es el comportamiento del kernel polinómico de la SVM. Amado y Dela Cruz justifican su elección afirmando que este kernel ofrece mejor rendimiento en problemas con más de dos predictores, y reportaron resultados excelentes con él. Sin embargo, en nuestro experimento fue el peor kernel evaluado con diferencia ($F1 = 0.5242$ para $C = 1.0$). Existen diferencias metodológicas concretas que podrían explicar esta discrepancia: su estudio no aplica (o por lo menos no menciona) ningún tipo de normalización, trabaja con únicamente 750 instancias con partición 70/30 sin estratificación, y excluye explícitamente la clase *Hazardous* del dataset. Cualquiera de estos factores podría influir en el comportamiento del kernel polinómico, lo que refuerza la conclusión de Sasmita et al. (2024) sobre la importancia crítica de la estrategia de preprocesado en modelos geométricos.

4.3.7 Análisis de significación estadística y robustez

A pesar de que el promedio aritmético sitúa a la arquitectura de Máquinas de Vectores de Soporte (SVM) con una ligera ventaja sobre la Red Neuronal Artificial (ANN), 0.947 frente a 0.944, resulta metodológicamente necesario verificar si esta diferencia posee significación estadística. En problemas de monitorización de calidad del aire, la validación cruzada de 5 pliegues proporciona la base empírica para este contraste.

Como paso previo, se evaluó la distribución de los resultados (Figura 16) mediante el test de Shapiro-Wilk. Los valores obtenidos ($p = 0.8054$ para SVM y $p = 0.8910$ para ANN) no rechazan la hipótesis de normalidad. No obstante, con $N = 5$, el test carece de potencia para detectar desviaciones significativas. Por ello, se optó por el test de rangos con signo de Wilcoxon, más robusto ante muestras pequeñas.

Al ejecutar el contraste, es imperativo considerar la naturaleza estocástica de las ANN. Dependiendo de la inicialización, la SVM logra superar a la ANN en la práctica totalidad de los pliegues (4 o 5 de 5 posibles). Matemáticamente, el p -valor mínimo alcanzable con $N = 5$ es $p = 0.0625$ (5 victorias) o $p = 0.1250$ (4 victorias). En ambos escenarios, al ser $p > 0.05$, no se dispone de evidencia suficiente para rechazar la hipótesis nula de igualdad de rendimiento. Sin embargo, la consistencia de la SVM en el conteo de pliegues refuerza su selección como el modelo más fiable.

En conclusión, el rendimiento predictivo se considera estadísticamente equivalente. La elección final debe fundamentarse en métricas operativas: la SVM es la candidata ideal por su menor coste computacional y velocidad de convergencia, factores críticos para el *edge computing* necesario en estaciones meteorológicas de dimensiones reducidas.

5 Conclusiones

Este informe abordó el problema de clasificación de la calidad del aire utilizando cinco modelos de aprendizaje automático: Redes de Neuronas Artificiales (ANN), Máquinas de Vectores de Soporte (SVM), k -Vecinos más Cercanos (k -NN), Árboles de Decisión y *Development of Mathematical Expressions* (DoME). El objetivo principal fue identificar la solución algorítmica más robusta para anticipar episodios de contaminación críticos, permitiendo una respuesta proactiva ante riesgos para la salud pública.




Figure 16: Distribución y dispersión de los resultados del F1-Score global en los 5 pliegues de validación cruzada para SVM y ANN.

El análisis experimental demuestra que el aprendizaje automático es una herramienta altamente eficaz para esta tarea, logrando que todos los modelos evaluados superen el umbral de 0.92 en métricas de F1-Score global. De la comparativa detallada se extraen los siguientes hallazgos fundamentales:

- **Superioridad en fronteras no lineales:** Las SVM con kernel gaussiano ($F1 = 0.947$) y las arquitecturas profundas de ANN ($F1 = 0.944$) se consolidan como las opciones más fiables. Su éxito radica en la capacidad para modelar interacciones complejas entre la química de los contaminantes y los factores ambientales. No obstante, les sigue de cerca DoME; el cual, a pesar de ser el más costoso computacionalmente de los cinco, lo compensa con unas métricas muy poco por debajo de las obtenidas con ANN y SVM.
- **El valor del contexto físico:** Se ha validado que las variables meteorológicas y geográficas (temperatura y proximidad industrial) actúan como predictores de contexto críticos. Esto permite al sistema asimilar la "huella climática" de la contaminación, superando la simple suma de métricas del AQI tradicional.
- **Viabilidad operativa y IoT:** El rendimiento del algoritmo DoME de Rivero et al. (2022) ($F1 = 0.940$) supone un hallazgo de gran relevancia práctica. Al generar ecuaciones algebraicas estándar y deterministas, DoME permitiría integrar la lógica predictiva directamente en microcontroladores de sensores IoT o estaciones meteorológicas de bajo coste, eliminando la dependencia de pesadas librerías de cálculo en tiempo real.
- **Vulnerabilidad geométrica:** Modelos basados en proximidad o partición ortogonal (k -NN y Árboles de Decisión), aunque computacionalmente ligeros, demostraron una mayor vulnerabilidad a la superposición de clases en el espacio de características.

Finalmente, la principal limitación técnica identificada reside en el desbalanceo intrínseco de los datos medioambientales. Mientras que la caracterización de aire "Bueno" roza la perfección empírica (> 0.997), la sensibilidad (*recall*) ante eventos de la clase "Peligroso" no logra superar el 0.80 en ningún escenario.

Esto subraya que el verdadero reto del estado del arte no es la clasificación general, sino el modelado del ruido en las zonas frontera. Aunque la naturaleza sintética del dataset facilitó la obtención de métricas consistentes, el despliegue de estos sistemas en redes de monitorización reales requerirá estrategias agresivas de remuestreo para garantizar la fiabilidad en la detección de los episodios más críticos para la ciudadanía.

6 Trabajo futuro

A partir de los resultados obtenidos y las limitaciones encontradas, se proponen las siguientes áreas de mejora:

6.1 Técnicas de remuestreo

El trabajo futuro a corto plazo debería centrarse en técnicas de *resampling* para paliar el desbalanceo de la variable objetivo, que fue identificado como la principal limitación del dataset a la hora de clasificar instancias como *Peligroso* o *Pobre*. Existen dos enfoques: el *submuestreo*, que reduce el número de instancias de la clase mayoritaria hasta igualar las clases minoritarias, y el *sobremuestreo*, que duplica instancias aleatorias de las clases minoritarias hasta igualar la mayoritaria.

Ambas técnicas presentan limitaciones obvias: el submuestreo descarta información que podría ser útil para el entrenamiento de los modelos, y el sobremuestreo genera instancias artificiales que podrían sobreajustar el modelo sobre regiones específicas que haya sido especialmente favorecidas por el algoritmo.

Una de las alternativas más utilizadas al remuestreo clásico es **SMOTE** (*Synthetic Minority Over-sampling Technique*) Chawla et al. (2002), que genera instancias sintéticas de las clases minoritarias mediante interpolación lineal entre instancias reales. Para cada instancia minoritaria x_i , el algoritmo selecciona uno de sus k vecinos más cercanos (típicamente $k = 5$) dentro de la misma clase, denominado x_j , y genera una nueva instancia x_{nuevo} situada aleatoriamente sobre el segmento que une ambos puntos:

$$x_{nuevo} = x_i + \lambda \cdot (x_j - x_i), \quad \lambda \sim U(0, 1) \quad (7)$$

donde λ es un valor aleatorio uniforme entre 0 y 1. La Figura 17 ilustra gráficamente el proceso.




Figure 17: Generación de instancias sintéticas mediante SMOTE. La nueva instancia x_{nuevo} se sitúa sobre el segmento que une la instancia x_i con uno de sus k vecinos más cercanos x_j .

Este enfoque resulta especialmente adecuado para el problema abordado, ya que el dataset cuenta con 9 atributos numéricos continuos sobre los que la interpolación lineal tiene sentido geométrico. La aplicación de SMOTE sobre las clases *Pobre* y *Peligroso* permitiría equilibrar la distribución sin descartar información de la clase mayoritaria. Existen, además, variantes refinadas como *Borderline-*

SMOTE o *ADASYN*, que centran la generación sintética en las fronteras de decisión, donde los modelos son más vulnerables.

6.2 Selección de características

Como se documentó en la figura 9, las variables PM2.5 y PM10 presentan una correlación de Pearson de 0,973, lo que indica una fuerte multicolinealidad. Otra línea de trabajo futuro consistiría en la eliminación de atributos redundante mediante selección de características. Entre las ventajas se incluyen:

- **Reducción de la multicolinealidad:** si dos variables están muy correlacionadas, aportan información casi idéntica, lo que introduce ruido en modelos como SVM o ANN que las interpretan como atributos independientes. Entrenar con la menor información repetida posible, aunque se pierde cierto conocimiento, puede ayudar al modelo a generalizar mejor.
- **Mejora de la generalización:** como ya mencionamos, a menor número de variables, más sencillo es el modelo y menos parámetros tiene que ajustar. El modelo aprendería patrones generales y evitaría aprender ruido.
- **Reducción del coste computacional:** cuanto menor es la dimensión, menor es el tiempo de entrenamiento y predicción del modelo. Aunque en nuestro escenario los tiempos ya son muy bajos, en un escenario real, donde contamos con cientos de características, la reducción podría ser considerable.
- **Mayor interpretabilidad:** si el modelo depende de menos variables, es más fácil explicar qué factores determinan la calidad del aire. Este es uno de los objetivos fundamentales en el área hoy en día.

Entre las técnicas aplicables se encuentran la eliminación basada en correlación, la importancia por permutación, los métodos *wrapper* con validación cruzada y técnicas de análisis de componentes principales (PCA) para reducir dimensionalidad preservando varianza.

6.3 Modelos de ensemble y estado del arte

El análisis de la bibliografía mostró que los modelos de *ensemble*, en concreto Random Forest y XGBoost, son los más utilizados en el estado del arte para problemas de calidad del aire. Estos modelos combinan múltiples árboles de decisión mediante técnicas de *bagging* o *boosting*, mitigando los problemas de los árboles individuales (alta varianza, fronteras ortogonales) y obteniendo mejores resultados en datasets desbalanceados. Una extensión natural del trabajo sería incorporar estos modelos a la comparativa para verificar si superan el rendimiento de SVM y ANN en este dataset concreto.

Respecto a esto, siguiendo las propuestas de Rivero et al. (2022), resultaría de gran interés explorar la creación de arquitecturas híbridas. Se propone el desarrollo de un ensemble que integre las Redes Neuronales Artificiales como nodos dentro del proceso de búsqueda de DoME. Esta hibridación permitiría combinar la interpretabilidad y portabilidad de la regresión simbólica con la capacidad de extracción de características de alto nivel de los modelos conexionistas, optimizando la precisión en la detección de umbrales críticos de calidad del aire.

6.4 Validación con datos reales y desarrollo del dataset

Una de las limitaciones principales de los datos es su carácter sintético, evidenciado por la presencia de valores físicamente imposibles. Validar los modelos con datos procedentes de estaciones meteorológicas reales, como las de la red europea de calidad del aire (EEA) o las de la Environmental Protection Agency (EPA) estadounidense, permitiría generalizar los resultados a escenarios reales.

Además, la introducción de nuevas características podría abrir nuevas líneas de investigación:

- **Dimensión temporal:** Incorporar series temporales permitiría predecir la evolución de la calidad del aire, no solo clasificar instancias aisladas.
- **Dimensión geográfica:** Añadir coordenadas geográficas habilitaría el análisis de patrones espaciales y la aplicación de técnicas de *geospatial machine learning*.

- **Mayor granularidad del target:** Pasar de las 4 categorías actuales a las 6 establecidas por el AQI estándar proporcionaría resultados más interpretables.

References

- Amado, T. M. and Dela Cruz, J. C. (2018). Development of machine learning-based predictive models for air quality monitoring and characterization. In *TENCON 2018 - 2018 IEEE Region 10 Conference*, pages 0668–0672.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.
- Emeç, M. and Yurtsever, M. (2025). A novel ensemble machine learning method for accurate air quality prediction. *International Journal of Environmental Science and Technology*, 22(1):459–476.
- Hamami, F. and Fithriyah, I. (2020). Classification of air pollution levels using artificial neural network. In *2020 International Conference on Information Technology Systems and Innovation (ICITSI)*, pages 217–220.
- Handayani, A. S., Soim, S., Agusdi, T. E., and Husni, N. L. (2021). Air quality classification using support vector machine. *Computer Engineering and Applications*, 10(1).
- Jirapattarasakul, S., Jirapattarasakul, S., Thanyacharoen, S., Akkaralaertsest, T., and Yingthawornsuk, T. (2025). Comparative analysis of deep learning and machine learning approaches for air quality prediction. In *2025 13th International Electrical Engineering Congress (iEECON)*, pages 1–6.
- Lee, M., Lin, L., Chen, C.-Y., Tsao, Y., Yao, T.-H., Fei, M.-H., and Fang, S.-H. (2020). Forecasting air quality in taiwan by using machine learning. *Scientific Reports*, 10(1):4153.
- Madan, T., Sagar, S., and Virmani, D. (2020). Air quality prediction using machine learning algorithms –a review. In *2020 2nd International Conference on Advances in Computing, Communication Control and Networking (ICACCCN)*, pages 140–145.
- Rivero, D., Fernandez-Blanco, E., and Pazos, A. (2022). Dome: A deterministic technique for equation development and symbolic regression. *Expert Systems with Applications*, 198:116712.
- Rybarczyk, Y. and Zalakeviciute, R. (2018). Machine learning approaches for outdoor air quality modelling: A systematic review. *Applied Sciences*, 8(12).
- Sasmita, N. R., Ramadeska, S., Kesuma, Z. M., Noviandy, T. R., Maulana, A., Khairul, M., and Suhendra, R. (2024). Decision tree versus k-nn: A performance comparison for air quality classification in indonesia. *Infolitika Journal of Data Science*, 2(1):9–16.
- Tang, D., Zhan, Y., and Yang, F. (2024). A review of machine learning for modeling air quality: Overlooked but important issues. *Atmospheric Research*, 300:107261.
- U.S. Environmental Protection Agency (EPA) (2024). Technical assistance document for the reporting of daily air quality. Technical report, Office of Air Quality Planning and Standards.
- Vishwakarma, H. K., M S, G. P., Mittal, V., Mittal, M., Naik, P., and S, C. (2025). Assessing the accuracy of regression and classification models in air quality prediction. In *2025 Fifth International Conference on Advances in Electrical, Computing, Communication and Sustainable Technologies (ICAECT)*, pages 1–6.